Projeto 3 – Modelo generativo para o Fashion-MNIST com Autoencoders Variacionais convolucionais

Aline Breda Kuster (RA: 168495)
Introdução às Redes Neurais Artificiais – UNIFESP
Repositório: https://github.com/aline-kuster/Projeto-3---Redes-Neurais

1 Metodologia

1.1 Dados

O Fashion-MNIST tem 70 000 imagens 28×28 em tons de cinza, divididas em 10 classes: camiseta, calça, pulôver, vestido, casaco, sandália, camisa, tênis, bolsa e bota. Os pixels foram divididos por 255 para ficar em $[0, 1]$. Dos 60 000 exemplos de treino originais, separei 600 de cada classe (6 000 no total) para **validação**, de forma estratificada e com semente fixa, e os 54 000 restantes foram para **treino**. Os 10 000 exemplos de **teste** só foram usados na análise final. Os rótulos não participam do treino dos VAEs: eles só entram na análise do espaço latente.

1.2 Modelo

O VAE aprende um encoder $q_\phi(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \operatorname{diag} \boldsymbol{\sigma}^2)$ e um decoder $p_\theta(\mathbf{x} \mid \mathbf{z})$, com prior $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$. A amostra é obtida pelo truque da reparametrização, $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\varepsilon}$ com $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, e a função de custo é o negativo do limite inferior da evidência (ELBO), por imagem:

$$\mathcal{L}(\mathbf{x}) = \underbrace{\sum_{i=1}^{784} \mathrm{BCE}(x_i, \hat{x}_i)}_{\text{reconstrução}} + \underbrace{\tfrac{1}{2} \sum_{j=1}^{d} \left(\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1 \right)}_{D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \,\|\, \mathcal{N}(\mathbf{0},\mathbf{I}))} . \tag{1}$$

Como o pixel é tratado como uma Bernoulli, o termo de reconstrução é a entropia cruzada binária somada nos 784 pixels. Ela foi calculada direto dos *logits* da última camada, o que é numericamente mais estável. Todas as perdas estão em nats por imagem.

Usei uma arquitetura **convolucional**, porque as convoluções aproveitam a estrutura espacial da imagem (bordas, golas, solas) com muito menos pesos por camada do que uma camada densa sobre os 784 pixels:

- **Encoder:** Conv 4×4, stride 2 (c_1 filtros, $28 \to 14$) $\to$ Conv 4×4, stride 2 (c_2 filtros, $14 \to 7$) $\to$ densa com h unidades $\to$ duas cabeças lineares, $\boldsymbol{\mu}$ e $\log \boldsymbol{\sigma}^2$, de dimensão d.
- **Decoder:** espelho do encoder. Densa $d \to h \to c_2 \cdot 7 \cdot 7$, depois duas convoluções transpostas ($7 \to 14 \to 28$) e sigmoide na saída.
- BatchNorm depois das convoluções e LeakyReLU (0,2) como ativação. Otimizador Adam.

1.3 Busca de hiperparâmetros

A topologia (c_1/c_2 e h) e os hiperparâmetros de otimização foram escolhidos por **busca aleatória**, feita separadamente para $d = 2$ e $d = 8$, porque a melhor arquitetura pode ser diferente para

cada dimensão latente. O espaço de busca está na Tabela 1, que tem 36 combinações. Sorteei 8 combinações para cada d e treinei cada uma por 10 épocas, guardando a menor $-$ELBO de validação. A vencedora de cada d foi treinada de novo do zero por até 60 épocas, com parada antecipada (paciência de 6 épocas) e restauração dos pesos da melhor época de validação. O orçamento curto da busca foi uma escolha para caber em CPU: cada configuração levou de 1,5 a 7 minutos.

Tabela 1: Espaço de busca. Cada linha é um hiperparâmetro e os valores sorteados.

Hiperparâmetro	Valores
Filtros das convoluções (c_1/c_2)	16/32, 32/64
Unidades da camada densa (h)	128, 256, 512
Taxa de aprendizado	$5 \cdot 10^{-4}$, 10^{-3}, $2 \cdot 10^{-3}$
Tamanho do lote	64, 128

1.4 Como o espaço latente foi avaliado

Cada imagem é representada pela média $\boldsymbol{\mu}$ do encoder, para que os gráficos não dependam do ruído da amostragem. A PCA foi **ajustada nos códigos de treino** e aplicada aos de teste. Todos os gráficos e métricas usam o conjunto de teste. As três perguntas do enunciado foram tratadas com ferramentas diferentes:

1. **Há clusters?** É uma pergunta sobre a geometria dos pontos, então foi respondida *sem os rótulos*: um gráfico de densidade (hexbin) do mesmo espaço e o K-means com $k = 2, \ldots, 14$, avaliado pelo coeficiente de silhueta. Para saber se uma silhueta é alta ou baixa, calculei como referência a silhueta do K-means aplicado a pontos sorteados de uma gaussiana padrão, que não tem cluster nenhum: cerca de 0,31–0,33 em 2D e 0,07 em 8D.
2. **Os rótulos se separam?** Uma regressão logística (classificador *linear*) treinada nos códigos de treino e avaliada nos de teste, com a matriz de confusão. Também calculei o índice de Davies-Bouldin e a silhueta usando os rótulos como grupos, além do ARI e do NMI entre os clusters do K-means ($k = 10$) e as classes verdadeiras.
3. **Quanto da variância a projeção ilustra?** A razão de variância explicada por componente da PCA.

2 Treinamento e escolha do modelo

A Figura 1 mostra todas as configurações testadas. As diferenças entre elas são pequenas: cerca de 1,2 nats entre a melhor e a pior para $d = 2$ e 1,1 nats para $d = 8$, numa perda em torno de 240–260. Ou seja, dentro desse espaço o resultado é pouco sensível à topologia. Ainda assim aparece um padrão. Para $d = 2$, as três melhores usam 32/64 filtros, e a vencedora tem a camada densa mais larga (512) com a menor taxa de aprendizado. Para $d = 8$, a vencedora também usa 32/64 filtros, mas a camada densa tem metade do tamanho (256) e a taxa de aprendizado é o dobro. As arquiteturas finais são diferentes (Tabela 2): o modelo de $d = 8$ tem cerca de metade dos parâmetros do de $d = 2$.

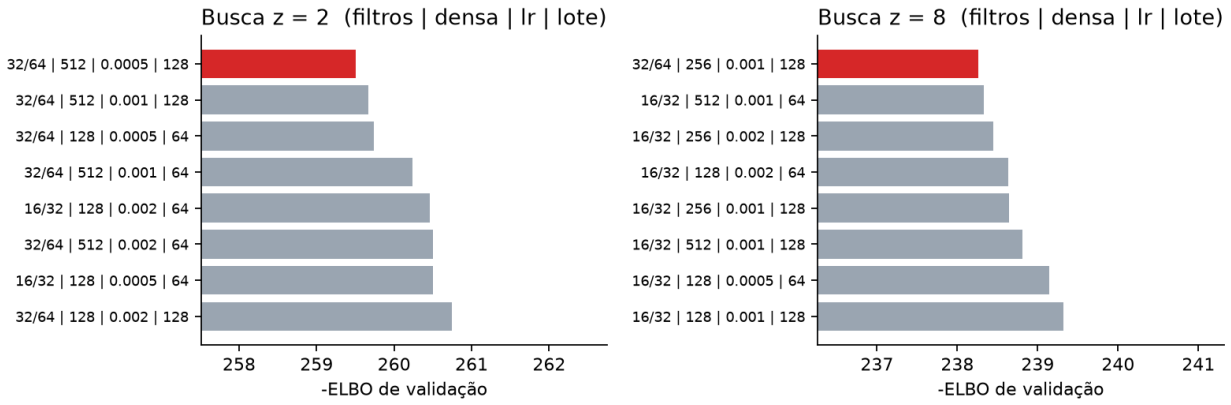


Figura 1: −ELBO de validação das 8 configurações sorteadas para cada dimensão latente (10 épocas cada). Em vermelho, a escolhida.

Tabela 2: Modelos finais. Perdas em nats por imagem. A −ELBO de teste é a média de 5 sorteios de $\mathbf{z}$. O PSNR compara cada imagem de teste com a reconstrução a partir de $\boldsymbol{\mu}$.

	Topologia				Teste			
Modelo	c_1/c_2, h	lr, lote	Parâm.	Val.	−ELBO	BCE	KL	PSNR (dB)
$d = 2$	32/64, 512	$5{\cdot}10^{-4}$, 128	3,29 M	255,91	258,00	251,55	6,44	16,60
$d = 8$	32/64, 256	10^{-3}, 128	1,68 M	234,72	236,86	222,67	14,20	20,14

As curvas da Figura 2 não mostram sobreajuste: treino e validação ficam juntos, e a diferença entre validação e teste é de só 2 nats. A melhor época foi a 56 para $d = 2$ e a 58 para $d = 8$, das 60 permitidas. Isso indica que a perda ainda caía devagar e que um orçamento maior traria um ganho pequeno, mas positivo.

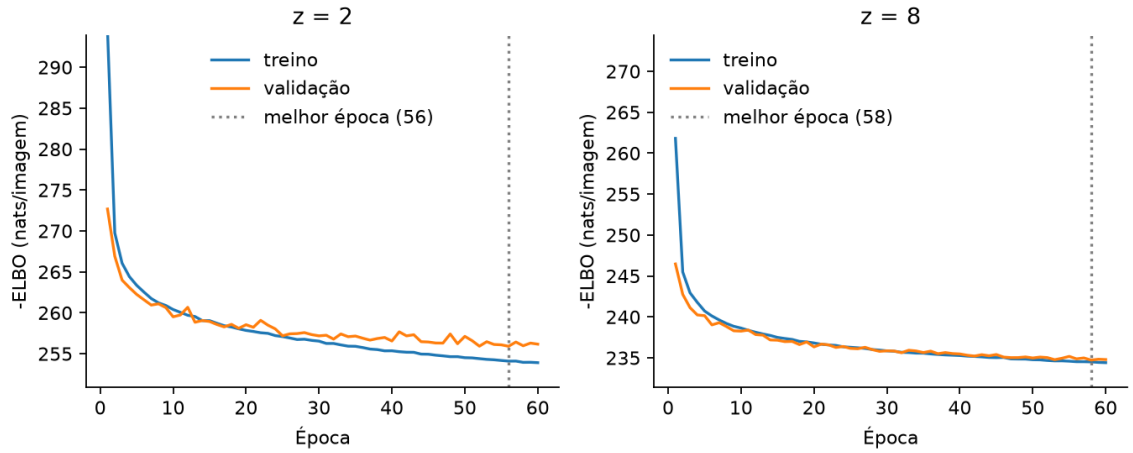


Figura 2: −ELBO por imagem no treino e na validação durante o treino final.

Passar de 2 para 8 dimensões reduz a reconstrução em 28,9 nats e aumenta a KL em 7,8 nats, uma melhora líquida de 21,1 nats na −ELBO. Com mais dimensões, o encoder guarda mais informação sobre cada peça e paga por isso no termo KL. O efeito aparece na Figura 3. Com $d = 2$ as reconstruções guardam a silhueta e o tom, mas viram um "protótipo" da classe: a sandália de salto alto perde as tiras, e a bolsa perde a forma e a alça. Com $d = 8$ a sandália mantém as tiras e o salto, o pulôver ganha a gola, e o vestido ganha volume na saia. Nos dois casos a estampa da

camiseta some, porque o decoder Bernoulli independente por pixel tende a produzir a média das possibilidades, que é borrada.



Figura 3: Uma imagem de teste por classe (primeira linha) e as reconstruções a partir de $\boldsymbol{\mu}$.

Na geração (Figura 4), as amostras de $d = 2$ são sempre reconhecíveis, mas parecidas entre si e borradas. As de $d = 8$ têm mais detalhe e variedade (tênis com sola marcada, peças com recortes e estampas), mas algumas saem fragmentadas. Em 8 dimensões, os códigos de treino não ocupam toda a massa da $\mathcal{N}(\mathbf{0}, \mathbf{I})$, e alguns sorteios caem em regiões que o decoder quase não viu.

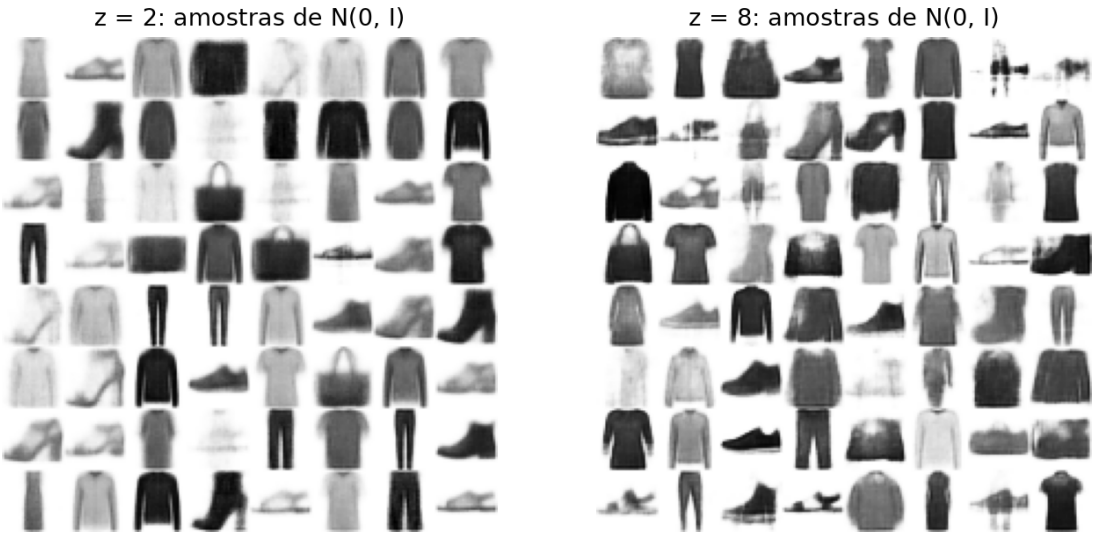


Figura 4: 64 imagens geradas por cada modelo a partir de $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

3 Espaço latente com 2 dimensões

Com $d = 2$ o latente pode ser desenhado sem projeção. A Figura 5 mostra o mesmo espaço duas vezes: com as cores das classes e só com a densidade de pontos, sem rótulos.

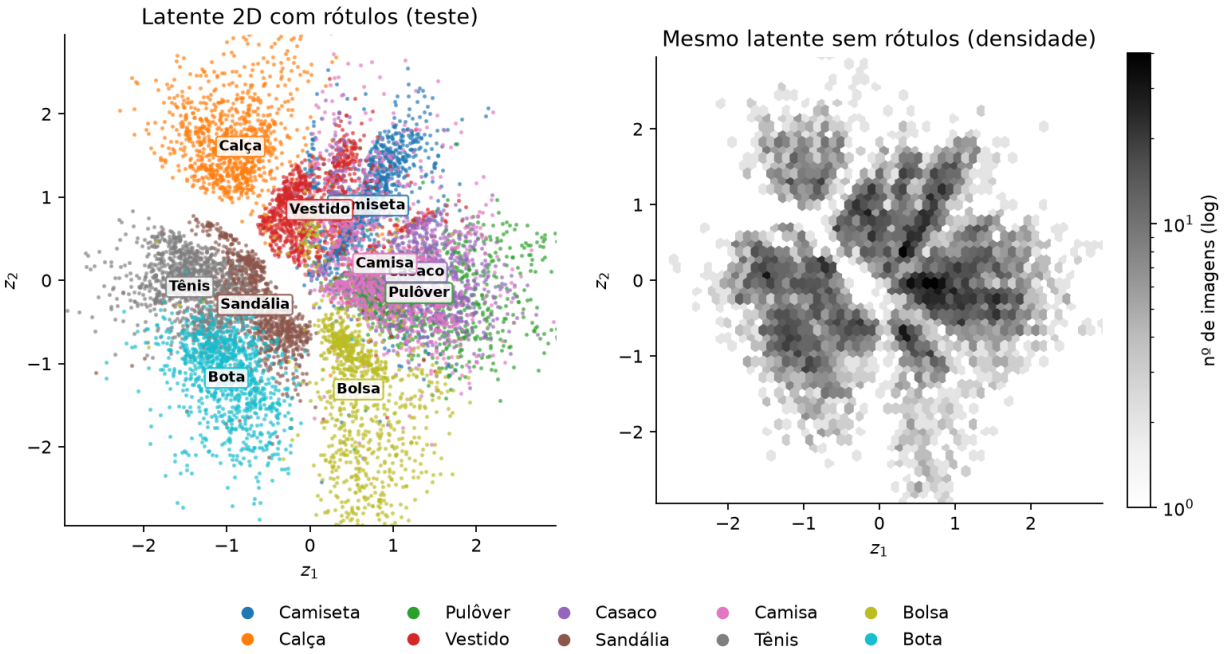


Figura 5: Médias $\boldsymbol{\mu}$ das 10 000 imagens de teste no latente de 2 dimensões. À esquerda, coloridas pela classe, com o nome no centróide. À direita, a densidade dos mesmos pontos (escala logarítmica), sem rótulos.

Organização. As classes ocupam "fatias" em torno da origem. Calça forma um grupo isolado no alto à esquerda. Os calçados ficam à esquerda, com tênis acima, sandália no meio e bota embaixo. Bolsa desce pelo centro, e as roupas de cima ficam à direita: camiseta e vestido no alto, pulôver, casaco e camisa juntos no lado direito. A densidade (direita) mostra que essas fatias *existem sem os rótulos*. Há quatro ou cinco lóbulos de alta densidade separados por faixas mais vazias que saem da origem, e o centro em si é pouco ocupado.

Manifold do decoder. A Figura 6 decodifica uma grade 15×15 nos quantis de 3% a 97% da normal padrão, então cada célula cobre a mesma massa de probabilidade do prior. As transições são contínuas: na coluna da esquerda o tênis vai ganhando cano até virar bota. Na linha de cima, a calça se funde num vestido e depois numa camiseta. Na direita, a camiseta ganha manga longa. No centro aparecem imagens apagadas e sobrepostas, que correspondem justamente à região de baixa densidade vista na Figura 5.

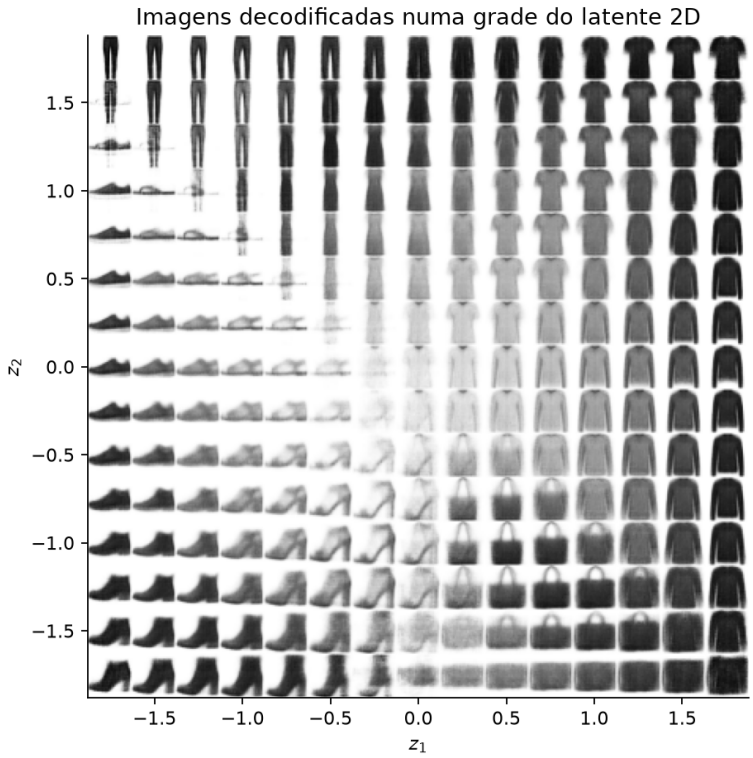


Figura 6: Imagens geradas pelo decoder de $d = 2$ numa grade regular do latente (quantis da normal padrão).

PCA com $d = 2$. Aplicar a PCA a um latente que já tem 2 dimensões só gira os eixos, e os dois componentes explicam 52,7% e 47,3% da variância. A nuvem é quase isotrópica (a variância de $\boldsymbol{\mu}$ é 1,14 e 1,06 por eixo), como o termo KL força. A informação de classe está na *direção angular* em torno da origem, e não numa direção de maior variância.

4 Espaço latente com 8 dimensões e projeção por PCA

4.1 Variância explicada

A Figura 7 mostra o espectro da PCA ajustada nos códigos de treino. Ele é quase plano: os componentes explicam de 14,1% a 10,7% cada um, e os **dois primeiros somam só 27,8%**. São necessários 4 componentes para passar de 50% e os 8 para passar de 90% (7 componentes chegam a 89,3%). Todas as 8 dimensões estão em uso: a variância de $\boldsymbol{\mu}$ fica entre 0,86 e 1,03 em cada dimensão do latente, e nenhuma colapsou para o prior.

O motivo do espectro plano é o próprio termo KL. Ele empurra a distribuição agregada dos códigos para $\mathcal{N}(\mathbf{0}, \mathbf{I})$, que tem a mesma variância em todas as direções, e a PCA só sabe ordenar direções por variância. Sem direções dominantes, qualquer plano 2D descarta cerca de 70% da variação.

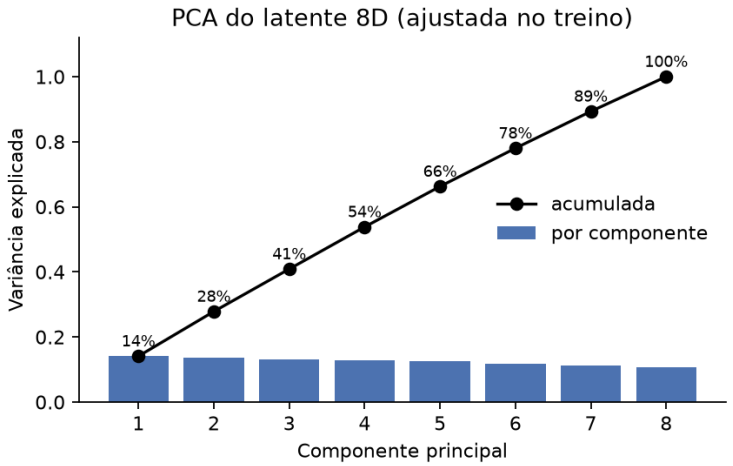


Figura 7: Variância explicada por componente (barras) e acumulada (linha) no latente de 8 dimensões.

4.2 Projeção nos dois primeiros componentes

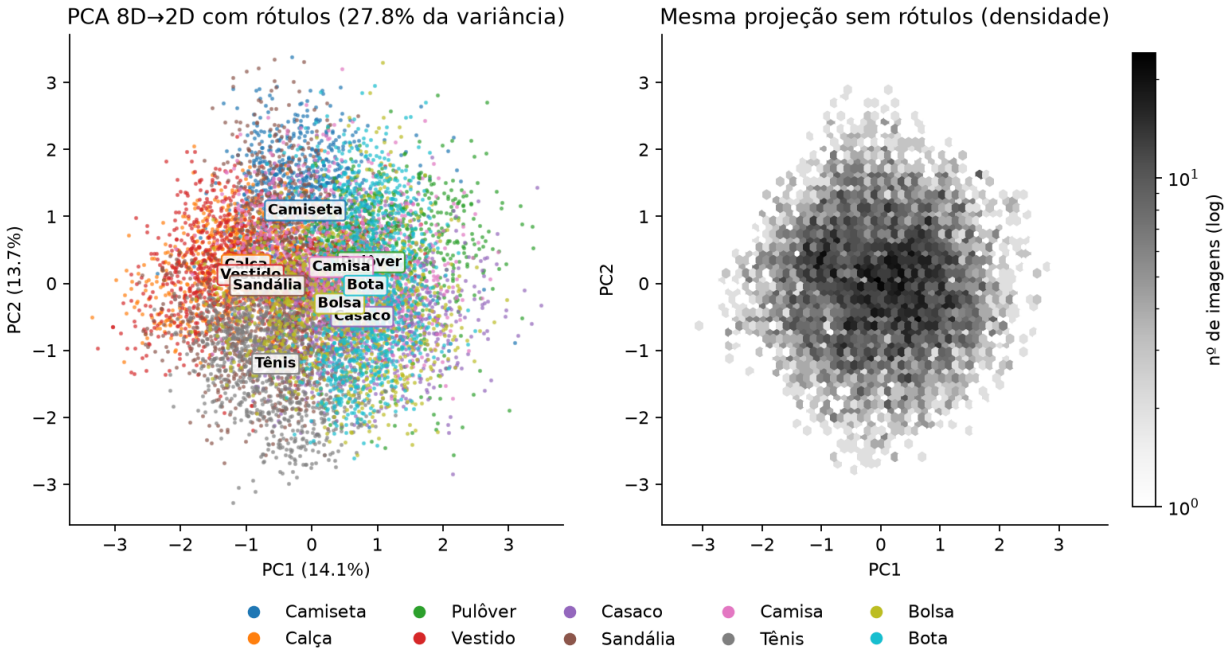


Figura 8: Projeção das médias $\boldsymbol{\mu}$ de teste nos dois primeiros componentes principais do latente de 8 dimensões. À esquerda, com rótulos. À direita, a densidade sem rótulos.

Na Figura 8 há tendências: vestido e calça à esquerda, tênis embaixo, camiseta no alto, pulôver e bota à direita. Mas os centróides ficam todos amontoados perto da origem, e as classes se sobrepõem numa nuvem única. O gráfico de densidade confirma isso: no plano PC1×PC2 há **um único aglomerado** em forma de gaussiana, sem lóbulos.

A Figura 9 mostra que a informação de classe não sumiu: ela está espalhada por outros componentes. No plano PC1×PC3 os calçados (tênis e sandália no alto à esquerda, bota no alto à direita) se separam bem do vestido e do casaco, e no plano PC3×PC4 a bota forma um grupo próprio. Cada par de componentes mostra um pedaço diferente da estrutura, e nenhum mostra tudo.

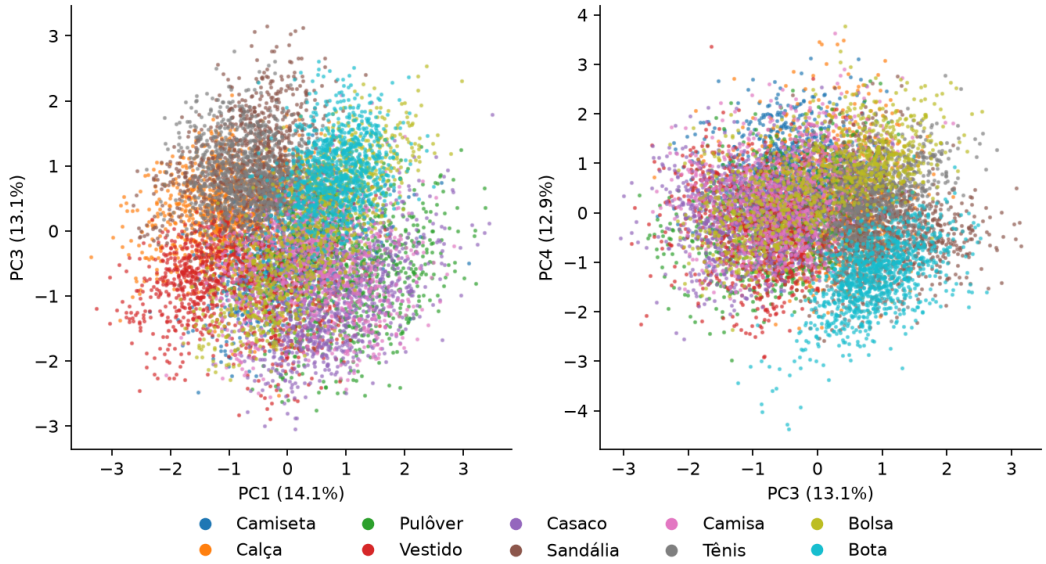


Figura 9: Outros pares de componentes principais do latente de 8 dimensões (conjunto de teste).

4.3 Interpolação no latente de 8 dimensões

Para ver se o espaço de 8 dimensões é contínuo, interpolei linearmente entre os códigos de duas imagens de classes diferentes (Figura 10). As transições são suaves e plausíveis. O tênis ganha cano até virar bota, as pernas da calça se juntam até formar um vestido, e a manga da camiseta cresce até virar camisa. Entre sandália e bolsa, o caminho passa por um tênis antes de chegar à bolsa: a reta entre os dois códigos atravessa a região dos calçados fechados.

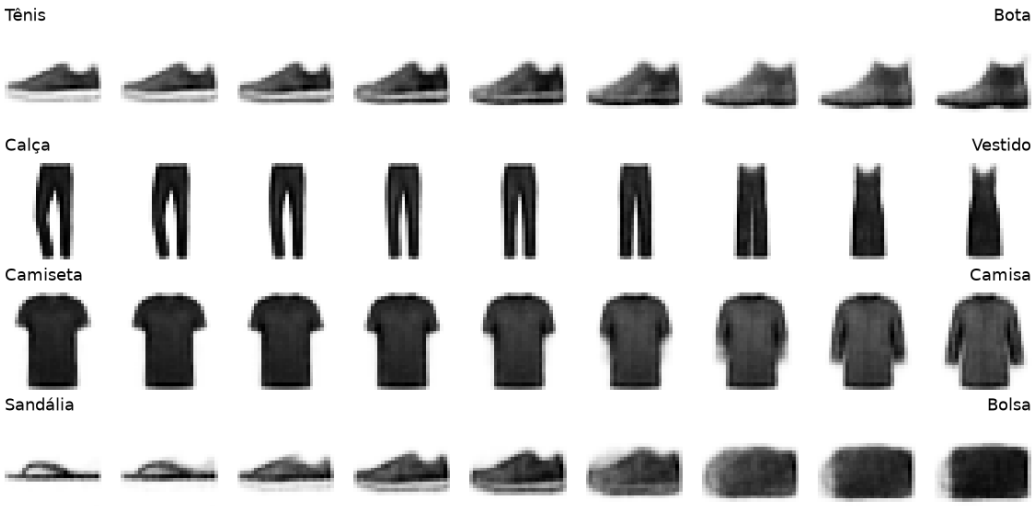


Figura 10: Decodificação de 9 pontos igualmente espaçados na reta entre os códigos de duas imagens de teste ($d = 8$).

5 Respostas às questões

Tabela 3: Métricas do espaço latente (conjunto de teste). Silhueta K-means: melhor k entre 2 e 14 (referência para dados sem clusters: $\approx 0{,}32$ em 2D e $\approx 0{,}07$ em 8D). Acurácia: regressão logística treinada nos códigos de treino. DB: Davies-Bouldin com os rótulos (menor é melhor).

	Clusters sem rótulos		Separação dos rótulos			
Representação	Silh. K-means (melhor k)	Referência	Acurácia	DB	ARI	NMI
$d = 2$ (latente completo)	0,420 ($k = 3$)	0,32	67,2%	2,37	0,41	0,57
$d = 8$ (latente completo)	0,129 ($k = 12$)	0,07	76,2%	3,03	0,35	0,51
$d = 8$ (PCA, 2 componentes)	0,342 ($k = 6$)	0,32	30,7%	5,94	0,11	0,23

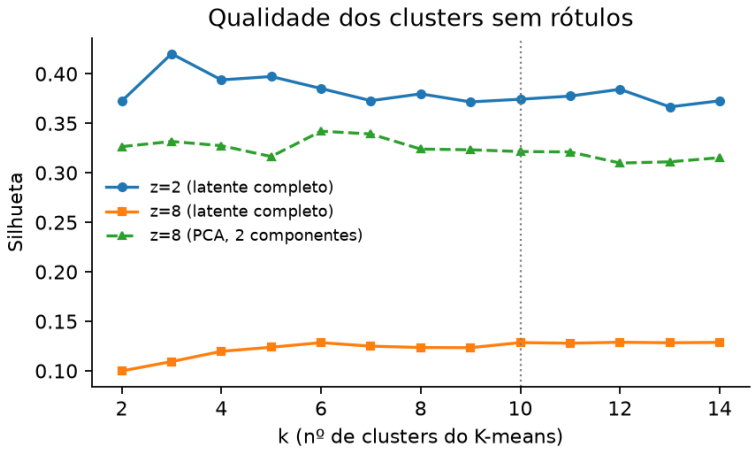


Figura 11: Silhueta do K-means em função de k, para cada representação.

Há formação de clusters no espaço latente?

Com $d = 2$, sim, mas poucos e largos. O gráfico de densidade (Figura 5) mostra lóbulos separados por regiões vazias, e a silhueta do K-means (0,42 com $k = 3$) fica acima da referência de 0,32 de uma gaussiana sem estrutura. O melhor k é 3, e não 10. Os grupos naturais correspondem a *famílias* de peças (calçados, roupas de cima, calça/bolsa), e não às 10 classes.

Com $d = 8$, há estrutura além do acaso, mas os grupos não são compactos. A silhueta de 0,13 é baixa em termos absolutos, mas é quase o dobro da referência de 0,07 de uma gaussiana 8D, e ela continua subindo até $k \approx 10$–12 (Figura 11). Os grupos existem, porém são alongados e encostam uns nos outros, o que a silhueta pune.

Na projeção PCA 2D do latente de 8 dimensões, não. A silhueta (0,34) é praticamente igual à de uma gaussiana 2D sem clusters (0,32), e a densidade da Figura 8 é unimodal. Os clusters que existem em 8D somem na projeção.

Há separação dos rótulos no espaço latente?

Parcial, e depende muito da classe. Os rótulos nunca foram usados no treino, mas um classificador *linear* acerta 67,2% das classes no latente de 2 dimensões e 76,2% no de 8 (o acaso seria 10%). A Figura 12 mostra onde estão os erros:

- **Bem separadas:** calça (90–92%), bota (89–91%), bolsa (88–90%), sandália e tênis (80–83%). São peças com silhuetas bem diferentes das demais.

- **Misturadas:** pulôver, casaco e camisa. Com $d = 2$ elas ficam entre 31% e 42% de acerto, e um pulôver é classificado como casaco ou camisa em mais da metade das vezes. Com $d = 8$ pulôver e casaco sobem para 64%, mas camisa continua em 40%, confundida com camiseta, pulôver e casaco. Essas classes têm o mesmo formato (manga longa) e diferem por detalhes pequenos, como botões, zíper e gola, que o VAE não prioriza.

Há uma diferença entre as métricas. O latente de 8 dimensões separa melhor os rótulos (acurácia de 76,2% contra 67,2%), mas tem silhueta com rótulos menor (0,06 contra 0,12) e Davies-Bouldin maior (3,03 contra 2,37). A silhueta e o DB comparam distâncias entre centróides com o espalhamento dentro das classes, e essa comparação piora em mais dimensões, porque as distâncias ficam mais parecidas entre si e as classes ocupam regiões alongadas. O classificador só precisa de uma fronteira entre elas, e em 8 dimensões há mais espaço para traçá-la.

Na **projeção PCA**, a separação cai para 30,7% de acurácia, e o ARI entre K-means e classes cai de 0,35 para 0,11. A informação de classe está no latente de 8 dimensões, mas o plano dos dois primeiros componentes a descarta quase toda.

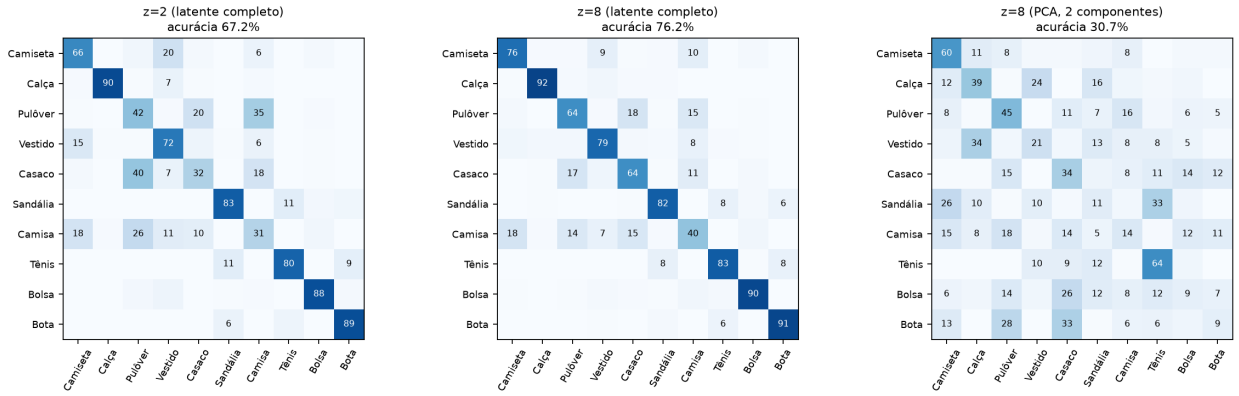


Figura 12: Matrizes de confusão (% por linha) da regressão logística no conjunto de teste. Valores abaixo de 5% foram omitidos.

A projeção ilustra quanto da variância?

27,8% (PC1 com 14,1% e PC2 com 13,7%). A projeção mostra pouco mais de um quarto da variação dos códigos. Isso explica por que ela parece uma nuvem única. O espectro da PCA é quase plano porque o termo KL deixa o latente próximo de uma gaussiana isotrópica, sem direções privilegiadas. Além disso, a PCA não usa os rótulos e não tem como saber que direções distinguem as classes. Com $d = 2$ não há redução: a "projeção" mostra 100% da variância, e por isso aquele gráfico tem estrutura visível.

6 Conclusão

O VAE convolucional com 8 dimensões reconstrói bem melhor que o de 2 ($-$ELBO de teste de 236,9 contra 258,0 nats, PSNR de 20,1 contra 16,6 dB) e organiza as classes de modo mais separável, apesar de nenhum rótulo ser usado no treino. Já o latente de 2 dimensões pode ser desenhado diretamente e mostra clusters visíveis, que correspondem a famílias de peças, e não às 10 classes. Projetar o latente de 8 dimensões com PCA é a forma mais fraca de visualizá-lo: o KL torna o espectro quase plano, os dois primeiros componentes guardam só 27,8% da variância e a estrutura de classes some. Em todos os casos, pulôver, casaco e camisa continuam difíceis de separar.

Possíveis próximos passos: treinar por mais épocas (a validação ainda caía na época 60), ampliar a

busca com profundidade da rede e um peso β no termo KL, e usar uma projeção não linear para visualizar o latente de 8 dimensões.

Código: `src/data.py` (dados), `src/model.py` (VAE e perda), `src/search.py` (busca e treino final) e `src/analyze.py` (métricas e figuras). Configurações e curvas completas em `results/search.json` e métricas em `results/metrics.json`.